#### **MANUAL CURSO DE AGVD**

# Página Oficial del Curso:

https://jdvelasq.github.io/courses/analitica-de-grandes-datos/

Todo el material ha sido construido por Juan David Velásquez, PhD, profesor asociado de la Universidad Nacional de Colombia para uso exclusivo de las clases de Analítica al interior del campus.

#### Laboratorios:

https://jdvelasq.github.io/courses/analitica-de-grandes-datos/grades.html

\* Para poder acceder debe estar ingresado en el listado, si por algún motivo no esta por favor reportarlo en Slack. Actualmente esta en proceso de carga por lo que favor revisar su usuario el día 30 de noviembre de 2019.

# Pagina Slack:

La página oficial del curso es: analiticagvdunalmed.slack.com

# Github con códigos:

https://github.com/amartinUnal/AnaliticaGVD/

En este se colocarán los códigos que se utilizarán en clase, estos corresponden a los mismos códigos de la Página Oficial del Curso con algunos ejemplos adicionales.

# Instalación y configuración de herramientas para la clase:

- 1. Crear una cuenta en github: https://jdvelasq.github.io/courses/analitica-de-grandes-datos/setup.html
- 2. Descargar e instalar VirtualBox + Vagrant específico para Linux (caso de que utilices Windows):

https://github.com/jdvelasq/vagrant4analytics

En caso de utilizar iOS / Linux se puede utilizar Docker directamente, para lo cual descargar e instalar Docker.

- Para acceder a Vagrant seguir las instrucciones del repositorio: https://jdvelasq.github.io/courses/analitica-de-grandes-datos/setup.html
  - \* En caso de tener problemas con el disksize al momento de usar Vagrant, instalar el paquete con la siguiente instrucción en línea de comandos:

vagrant plugin install vagrant-disksize

```
Administrator: Command Prompt
```

### vagrant@ubuntu-bionic: /vagrant

```
:\Users\
elcome to Ubuntu 18.04.3 LTS (GNU/Linux 4.15.0-70-generic x86_64)
 :\Users\
  * Documentation: https://help.ubuntu.com
  * Management:
                            https://landscape.canonical.com
https://ubuntu.com/advantage
  * Support:
   System information as of Wed Nov 27 19:56:35 UTC 2019
System load: 0.27 Processes: 120
Usage of /: 36.4% of 14.48GB Users logged in: 0
Welcome to Ubuntu 18.04.3 LTS (GNU/Linux 4.15.0-70-generic x86_64)
  * Documentation: https://help.ubuntu.com

* Management: https://landscape.canonical.com

* Support: https://ubuntu.com/advantage
  * Support:
   System information as of Wed Nov 27 19:56:35 UTC 2019
  System load: 0.27 Processes: Usage of /: 36.4% of 14.48GB Users logged in:
                                                                                         120
  Memory usage: 1%
Swap usage: 0%
                                                     IP address for enp0s3: 10.0.2.15
IP address for docker0: 172.17.0.1
  * Overheard at KubeCon: "microk8s.status just blew my mind".
       https://microk8s.io/docs/commands#microk8s.status
27 packages can be updated.
0 updates are security updates.
 ast login: Wed Nov 27 13:30:06 2019 from 10.0.2.2 
/agrant@ubuntu-bionic:~$ cd /vagrant 
/agrant@ubuntu-bionic:/vagrant$ _
```

- 4. Si tienes Linux / iOS corres el Docker descargando la versión especifica correspondiente al bloque de trabajo del curso.
  - Bloque 1: MapReduce
  - Bloque 2: Pig
  - Bloque 3: Hive
  - Bloque 4: Spark

#### Con la instrucción:

```
docker run --rm -it -v "$PWD":/datalake --name hive -p 50070:50070 -p 8088:8088 -
p 8888:8888 -p 5000:5000 jdvelasq/<nombre del contenedor>
```

- \* Si estas usando el vagrant con SO Ubuntu y te genera error de permisos, recuerda adicionar el sudo antes del docker.
- \* La versión pseudo monta hdfs, mientras que la versión standalone trabaja con el sistema de archivos local de la máquina. Por lo anterior la versión standalone puede ser de ejecución más rápida, pero la pseudo aprovecha el sistema de almacenamiento hdfs estándar cuando se trabaja en hadoop.
- \* Recuerda correrlo la primera vez en una red distinta a la de la universidad dado que se requiere acceso para descargar ciertos componentes como Docker, las cuales están restringidas al interior del campus. Luego de la primera ejecución los archivos quedan guardados en tu maquina y ya es posible ejecutarlo en la red del campus.

# 5. Bloque 1: MapReduce

Para la primera clase vamos a utilizar: https://colab.research.google.com

```
docker run --rm -it -v "$PWD":/datalake --name hadoop -p 50070:50070 -p 8088:8088
-p 8888:8888 -p 5000:5000 jdvelasq/hadoop:2.8.5-pseudo
```

```
Tool@9b3930be3ck:/datalake

**agrant@ubuntu-blont::/wagrant$ docker run --rm -it -v "$PMD":/datalake --name hadoop -p 50070:50070 -p 8088:80888 -p 8080:5000 jdvelasq/hadoop:2.8.5-pseudo

Could not load host key: /etc/ssh/ssh_host_rsa_key

Formatting using clusterid: CID-c7b0dc1a-4efb-4010-84d6-124e4b098a2d

Starting namenodes on [e.0.6.0] (ECDSA) to the list of known hosts.

0.0.0.0: starting namenode, logging to /usr/local/hadoop/logs/hadoop-root-namenode-9b3930be3c8c.out

localhost: starting datanode, logging to /usr/local/hadoop/logs/hadoop-root-datanode-9b3930be3c8c.out

Starting secondary namenodes [e.0.6.0] (ECDSA) to the list of known hosts.

localhost: starting datanode, logging to /usr/local/hadoop/logs/hadoop-root-datanode-9b3930be3c8c.out

Starting secondary namenodes [e.0.6.0] (ECDSA) to the list of known hosts.

localhost: starting secondarynamenode, logging to /usr/local/hadoop/logs/hadoop-root-atanode-9b3930be3c8c.out

starting resourcemanager, logging to /usr/local/hadoop/logs/yarn-root-nodemanager-9b3930be3c8c.out

Hadoop NameNode at:

http://127.0.0.1:8088/

**Tool@0b3930be3c8c:/datalake#
```

\* Para validar el funcionamiento de los nodos y del Yarn se puede ingresar al navegador la url 127.0.0.1 con el respectivo puerto

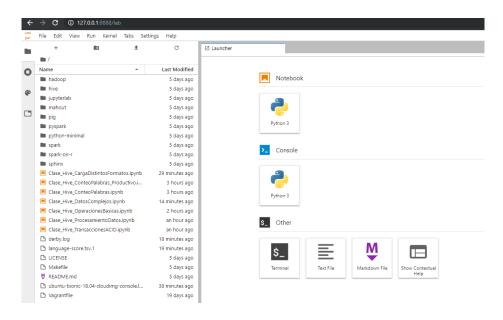
En este caso ya esta corriendo el docker para Hadoop, basta digitar Python o si se desea trabajar en Jupyter basta colocar la instrucción: jupyter lab --ip=0.0.0.0

```
root@9b3936be3c8c:/datalake# jupyter lab --ip=0.0.0
[1 23:07:31.456 LabApp] Writing notebook server cookie secret to /root/.local/share/jupyter/runtime/notebook_cookie_secret
[1 23:07:31.758 LabApp] JupyterLab extension loaded from /usr/local/lib/python3.6/dist-packages/jupyterlab
[1 23:07:31.758 LabApp] JupyterLab application directory is /usr/local/share/jupyter/lab
[1 23:07:31.922 LabApp] Serving notebooks from local directory: /datalake
[1 23:07:31.922 LabApp] The Jupyter Notebook is running at:
[1 23:07:31.922 LabApp] http://9b3936be3c8c:8888/?token=38e936cf45d66df4c6cd26f2f8e4eb8cddc3959e2e786632
[1 23:07:31.922 LabApp] or http://127.0.0.1:8888/?token=38e936cf45d66df4c6cd26f2f8e4eb8cddc3959e2e786632
[1 23:07:31.922 LabApp] Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).
[C 23:07:31.926 LabApp]

To access the notebook, open this file in a browser:
    file:///root/.local/share/jupyter/runtime/nbserver-1280-open.html

Or copy and paste one of these URLs:
    http://jb3936be3c8c:8888/?token=38e936cf45d66df4c6cd26f2f8e4eb8cddc3959e2e786632
or http://127.0.0.1:8888/?token=38e936cf45d66df4c6cd26f2f8e4eb8cddc3959e2e786632
```


Selecciona la url y la pegas en el explorador:



- https://jdvelasq.github.io/courses/notebooks/hadoop/1-01-intro-mapreduce.html
- <a href="https://jdvelasq.github.io/courses/notebooks/hadoop/1-03-wordcount-streaming-python.html">https://jdvelasq.github.io/courses/notebooks/hadoop/1-03-wordcount-streaming-python.html</a>
- https://jdvelasq.github.io/courses/notebooks/hadoop/1-04-wordcount-pythonefficient.html
- <a href="https://jdvelasq.github.io/courses/notebooks/hadoop/1-07-wordcount-standalone.html">https://jdvelasq.github.io/courses/notebooks/hadoop/1-07-wordcount-standalone.html</a>
- https://jdvelasq.github.io/courses/notebooks/hadoop/1-08-(opcional)wordcount-java-standalone.html


<a href="https://jdvelasq.github.io/courses/notebooks/hadoop/1-09-(opcional)-wordcount-java-pseudo.html">https://jdvelasq.github.io/courses/notebooks/hadoop/1-09-(opcional)-wordcount-java-pseudo.html</a>

# ejemplo:

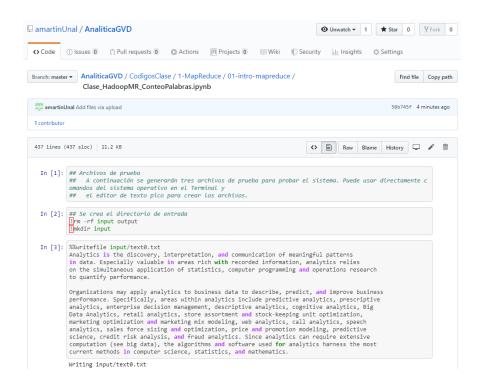


En caso de preferir por consola puedes utilizar el editor pico.

Los códigos están el github/AnaliticaGVD con sus respectivos resultados de ejecución en la estructura de carpetas por nombre:



### Archivo de conteo de palabras:



# 6. Bloque 2: Pig

```
docker run --rm -it -v "$PWD":/datalake --name pig -p 50070:50070 -p 8088:8088
-p 8888:8888 -p 5000:5000 jdvelasq/pig:0.17.0-pseudo
```

```
** root@3c409129cda1:/datalake
**agrant@ubuntu-bionic:/vagrant$ docker run --rm -it -v "$PWD":/datalake
**agrant@ubuntu-bionic:/vagrant$ docker run --rm -it -v "$PWD":/datalake
**Starting OpenBSD Secure Shell server sshd

formatting using clusterid: CID-5187c0f3-56d5-4531-a7ec-06bfd76e03a2

Starting namenodes on [0.0.0.0]
0.0.0.0: Manning: Permanently added '0.0.0.0' (ECDSA) to the list of known hosts.
0.0.0.0: starting namenode, logging to /usr/local/hadoop/logs/hadoop-root-namenode-3c409129cda1.out
localhost: Manning: Permanently added '10calhost' (ECDSA) to the list of known hosts.
localhost: Manning: Permanently added '10calhost' (ECDSA) to the list of known hosts.
localhost: Manning: Permanently added '10calhost' (ECDSA) to the list of known hosts.
localhost: starting datanode, logging to /usr/local/hadoop/logs/hadoop-root-datanode-3c409129cda1.out
Starting secondary namenodes [0.0.0.0]
0.0.0.0: starting secondary namenodes [0.0.0.0]
0.0.0.0: starting recourcemanager, logging to /usr/local/hadoop/logs/yarn-resourcemanager-3c409129cda1.out
localhost: starting nodemanager, logging to /usr/local/hadoop/logs/yarn-root-nodemanager-3c409129cda1.out

**Madoop NameNode at:

http://127.0.0.1:50070/

Varn ResourceManager at:

http://127.0.0.1:50070/

**Madoop NameNode At:

http://127.0.0.1:50070/

**Madoop Nam
```

\* Para validar el funcionamiento de los nodos y del Yarn se puede ingresar al navegador la url 127.0.0.1 con el respectivo puerto

En este caso ya esta corriendo el docker para pig, basta con escribir pig o si se desea trabajar en Jupyter basta colocar la instrucción: jupyter lab --ip=0.0.0.0

```
Selectroot@3c409129cda1:/datalake

root@3c409129cda1:/datalake# jupyter lab --ip=0.0.0.0

[1 00:35:18.298 LabApp] Writing notebook server cookie secret to /root/.local/share/jupyter/runtime/notebook_cookie_secret

[1 00:35:19.120 LabApp] JupyterLab extension loaded from /usr/local/lib/python3.6/dist-packages/jupyterlab

[1 00:35:19.120 LabApp] JupyterLab application directory is /usr/local/share/jupyter/lab

[1 00:35:19.557 LabApp] Serving notebooks from local directory: /datalake

[1 00:35:19.558 LabApp] http://3c409129cda1:8888/?token=f490ec29e91d86bd7146c3db510d893c75d2e9d71209320d

[1 00:35:19.558 LabApp] http://3c409129cda1:8888/?token=f490ec29e91d86bd7146c3db510d893c75d2e9d71209320d

[1 00:35:19.558 LabApp] Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).


[C 00:35:19.559 LabApp]

To access the notebook, open this file in a browser:
    file://root/.local/share/jupyter/runtime/nbserver-1368-open.html

Or copy and paste one of these URLs:
    http://3c409129cda1:8888/?token=f490ec29e91d86bd7146c3db510d893c75d2e9d71209320d


or http://3c409129cda1:8888/?token=f490ec29e91d86bd7146c3db510d893c75d2e9d71209320d
```

Selecciona la url y la pegas en el explorador:



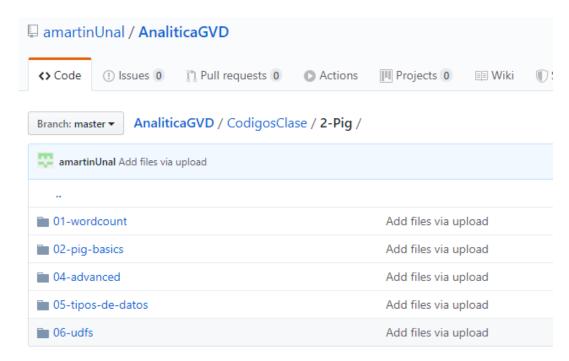
- https://jdvelasq.github.io/courses/notebooks/pig/1-01-wordcount-pig.html
- https://jdvelasq.github.io/courses/notebooks/pig/1-02-pig-basics.html
- https://idvelasg.github.io/courses/notebooks/pig/2-04-advanced.html
- https://jdvelasq.github.io/courses/notebooks/pig/2-05-tipos-de-datos.html
- https://jdvelasq.github.io/courses/notebooks/pig/2-06-udfs.html
- https://jdvelasg.github.io/courses/notebooks/pig/2-07-standalone.html

# ejemplo:




En caso de preferir por consola puedes utilizar el editor pico.

Los códigos están el github/AnaliticaGVD con sus respectivos resultados de ejecución en la estructura de carpetas por nombre:



# Archivo de conteo de palabras:



### 7. Bloque 3: Hive

docker run --rm -it -v "\$PWD":/datalake --name hive -p 50070:50070 -p 8088:8088 -p 8888:8888 -p 5000:5000 jdvelasq/hive:2.3.6-pseudo

```
The content of the co
```

\* Para validar el funcionamiento de los nodos y del Yarn se puede ingresar al navegador la url 127.0.0.1 con el respectivo puerto

En este caso ya esta corriendo el docker para hive, basta con escribir hive o si se desea trabajar en Jupyter basta colocar la instrucción:

jupyter lab -ip=0.0.0.0

```
root@499bf3956267:/datalake# jupyter lab --ip=0.0.0.0

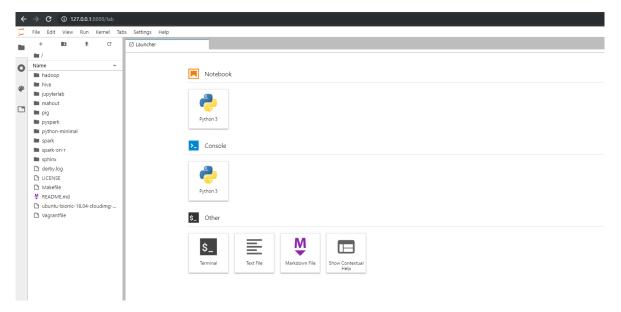
[1 20:05:38.191 LabApp] Writing notebook server cookie secret to /root/.local/share/jupyter/runtime/notebook_cookie_secret
[1 20:05:39.427 LabApp] Jupyterlab extension loaded from /usr/local/lib/python3.6/dist-packages/jupyterlab
[1 20:05:39.488 LabApp] Jupyterlab application directory is /usr/local/share/jupyter/lab
[1 20:05:39.888 LabApp] Serving notebooks from local directory: /datalake
[1 20:05:39.884 LabApp] The Jupyter Notebook is running at:
[1 20:05:39.884 LabApp] The Jupyter Notebook is running at:
[1 20:05:39.884 LabApp] or http://499bf3952667:8888/?token=8a362f08afa0c4eec7e79ee50494435de738a8c6c1926ec0
[1 20:05:39.884 LabApp] Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).
[C 20:05:39.898 LabApp]

To access the notebook, open this file in a browser:
    file://root/.local/share/jupyter/runtime/nbserver-1733-open.html

Or copy and paste one of these URLs:
    http://499bf3956267:8888/?token=8a362f08afa0c4eec7e79ee50494435de738a8c6c1926ec0


or http://127.0.0.1:8888/?token=8a362f08afa0c4eec7e79ee50494435de738a8c6c1926ec0
```

Selecciona la url y la pegas en el explorador:




- <a href="https://jdvelasq.github.io/courses/notebooks/hive/1-01-conteo-de-palabras-en-hive.html">https://jdvelasq.github.io/courses/notebooks/hive/1-01-conteo-de-palabras-en-hive.html</a>
- <a href="https://jdvelasq.github.io/courses/notebooks/hive/1-02-operaciones-basicas-en-hive.html">https://jdvelasq.github.io/courses/notebooks/hive/1-02-operaciones-basicas-en-hive.html</a>
- <a href="https://jdvelasq.github.io/courses/notebooks/hive/2-03-procesamiento-de-datos-con-hive.html">https://jdvelasq.github.io/courses/notebooks/hive/2-03-procesamiento-de-datos-con-hive.html</a>
- <a href="https://jdvelasq.github.io/courses/notebooks/hive/2-07-manejo-de-datos-complejos.html">https://jdvelasq.github.io/courses/notebooks/hive/2-07-manejo-de-datos-complejos.html</a>
- https://idvelasg.github.io/courses/notebooks/hive/2-08-standalone.html

# Ejemplo:

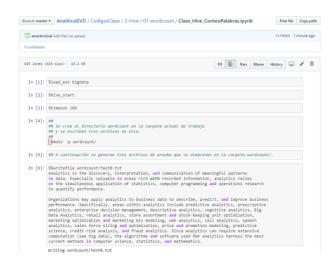


En caso de preferir por consola puedes utilizar el editor pico.

Los códigos están el github/AnaliticaGVD con sus respectivos resultados de ejecución en la estructura de carpetas por nombre:



# Archivo de conteo de palabras:



# 8. Bloque 4: Spark

```
docker run --rm -it -v "$PWD":/datalake --name pyspark -p 50070:50070 -p
8088:8088 -p 8888:8888 -p 5000:5000 jdvelasq/pyspark:2.4.4-pseudo
```

```
Tool@76028326a16e /datalake

**grant@ubuntu-bionic:/vagnant5 docker run --rm -it -v "$PWD":/datalake

**grant@ubuntu-bionic:/vagnant5 docker run --rm -it -v "$PWD":/datalake

**Starting OpenBDS Secure Shell server sshd

[OK]

formatting using clusterid: CID-ebe8a593-6b74-4899-8663-5988b5a10ca

Starting namenodes on [0.0.0.0]
0.0.0.0: Marning: Permanently added '0.0.0.0' (ECDSA) to the list of known hosts.
0.0.0.0: starting namenode, logging to /usr/local/hadoop/logs/hadoop-root-namenode-76028326a16e.out

localhost: Marning: Permanently added '10calhost' (ECDSA) to the list of known hosts.
10calhost: Marning: Permanently added '10calhost' (ECDSA) to the list of known hosts.
10calhost: Starting datanode, logging to /usr/local/hadoop/logs/hadoop-root-datanode-76028326a16e.out

Starting secondary namenodes [0.0.0.0]
0.0.0.0: starting secondarynamenodes [0.0.0.0]
0.0.0.0: starting secondarynamenodes [0.0.0.0]
0.0.0.0: starting resourcemanager, logging to /usr/local/hadoop/logs/yarn--resourcemanager-76028326a16e.out

starting resourcemanager, logging to /usr/local/hadoop/logs/yarn-root-nodemanager-76028326a16e.out

Hadoop NameNode at:

http://127.0.0.1:50070/

Yarn ResourceManager at:

http://127.0.0.1:50070/

Marn ResourceManager at:
```


\* Para validar el funcionamiento de los nodos y del Yarn se puede ingresar al navegador la url 127.0.0.1 con el respectivo puerto

En este caso ya esta corriendo el docker para trabajar con spark, basta con escribir el código en un archivo y ejecutarlo por línea de comandos (o instrucción a instrucción en Python) o si se desea trabajar en Jupyter basta colocar la instrucción: jupyter lab -- ip=0.0.0.0

```
Selectront@3c409129cda1:/datalake
root@3c409129cda1:/datalake# jupyter lab --ip=0.0.00
[I 00:35:18.298 LabApp] Writing notebook server cookie secret to /root/.local/share/jupyter/runtime/notebook_cookie_secret
[I 00:35:19.120 LabApp] JupyterLab extension loaded from /usr/local/lib/python3.6/dist-packages/jupyterlab
[I 00:35:19.120 LabApp] JupyterLab application directory is /usr/local/share/jupyter/lab
[I 00:35:19.557 LabApp] Serving notebooks from local directory: /datalake
[I 00:35:19.558 LabApp] The Jupyter Notebook is running at:
[I 00:35:19.558 LabApp] http://3c409129cda1:8888/?token=f490ec29e91d86bd7146c3db510d893c75d2e9d71209320d
[I 00:35:19.558 LabApp] or http://127.0.0.1:8888/?token=f490ec29e91d86bd7146c3db510d893c75d2e9d71209320d
[I 00:35:19.558 LabApp] Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).
[C 00:35:19.569 LabApp]

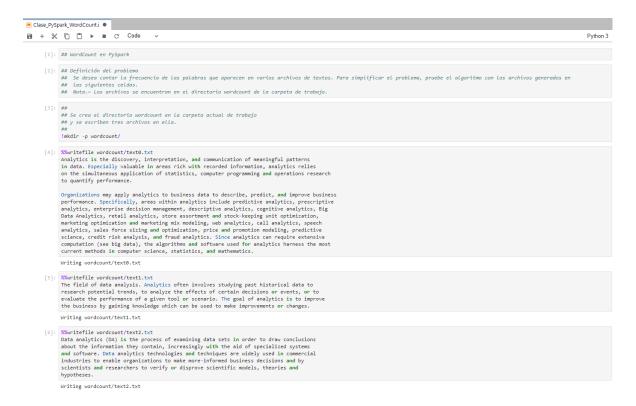
To access the notebook, open this file in a browser:
    file:///root/.local/share/jupyter/runtime/nbserver-1368-open.html
Or copy and paste one of these URLs:
    http://3c409129cda1:8888/?token=f490ec29e91d86bd7146c3db510d893c75d2e9d71209320d
    or http://127.0.0.1:8888/?token=f490ec29e91d86bd7146c3db510d893c75d2e9d71209320d
```

Selecciona la url y la pegas en el explorador:



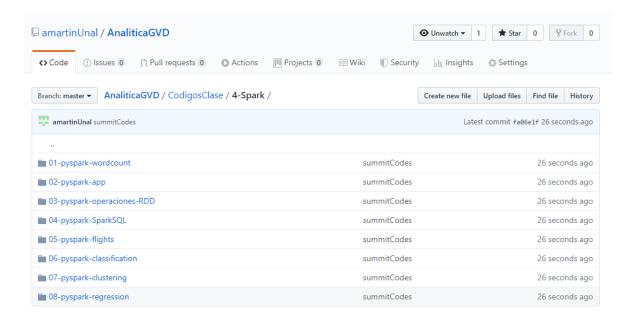
- <a href="https://jdvelasq.github.io/courses/notebooks/pyspark/1-01-pyspark-wordcount.html">https://jdvelasq.github.io/courses/notebooks/pyspark/1-01-pyspark-wordcount.html</a>
- https://jdvelasq.github.io/courses/notebooks/pyspark/1-02-pyspark-app.html
- <a href="https://jdvelasq.github.io/courses/notebooks/pyspark/1-03-pyspark-operaciones-RDD.html">https://jdvelasq.github.io/courses/notebooks/pyspark/1-03-pyspark-operaciones-RDD.html</a>
- <a href="https://jdvelasq.github.io/courses/notebooks/pyspark/1-04-pyspark-standalone.html">https://jdvelasq.github.io/courses/notebooks/pyspark/1-04-pyspark-standalone.html</a>
- <a href="https://jdvelasq.github.io/courses/notebooks/pyspark/2-04-pyspark-SparkSQL.html">https://jdvelasq.github.io/courses/notebooks/pyspark/2-04-pyspark-SparkSQL.html</a>
- https://jdvelasq.github.io/courses/notebooks/pyspark/2-05-pyspark-flights.html
- <a href="https://jdvelasq.github.io/courses/notebooks/pyspark/3-06-pyspark-classification.html">https://jdvelasq.github.io/courses/notebooks/pyspark/3-06-pyspark-classification.html</a>
- <a href="https://jdvelasq.github.io/courses/notebooks/pyspark/4-07-pyspark-clustering.html">https://jdvelasq.github.io/courses/notebooks/pyspark/4-07-pyspark-clustering.html</a>
- https://jdvelasq.github.io/courses/notebooks/pyspark/5-08-pysparkregression.html
- <a href="https://jdvelasq.github.io/courses/notebooks/pyspark/6-09-pyspark-strucStream.html">https://jdvelasq.github.io/courses/notebooks/pyspark/6-09-pyspark-strucStream.html</a>

### ejemplo:



En caso de preferir por consola puedes utilizar el editor pico.

Los códigos están el github/AnaliticaGVD con sus respectivos resultados de ejecución en la estructura de carpetas por nombre:



# Archivo de conteo de palabras:

